

**Министерство науки и высшего образования Российской Федерации**  
**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО**  
**ОБРАЗОВАНИЯ**

**«Национальный исследовательский университет ИТМО»**  
**(Университет ИТМО)**

**Школа разработки видеоигр**

**Образовательная программа Технологии разработки компьютерных игр**

**Направление подготовки (специальность) Прикладная информатика**

**О Т Ч Е Т**

о преддипломной практике

Тема задания: Методы генерации ландшафта для заполнения пустот в цифровых моделях рельефа

Обучающийся : Остапович Денис Евгеньевич, J4222

Согласовано:

Руководитель практики от профильной организации:

Руководитель практики от университета: Карсаков Андрей Сергеевич, кандидат технических наук, Университет ИТМО, Школа разработки видеоигр, доцент

Практика пройдена с оценкой \_\_\_\_\_

Дата \_\_\_\_\_

Санкт-Петербург  
2024

## ОГЛАВЛЕНИЕ

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ .....	4
ВВЕДЕНИЕ .....	5
1. АНАЛИЗ СУЩЕСТВУЮЩИХ ПОДХОДОВ .....	7
1.1 Традиционные алгоритмы интерполяции .....	7
1.1.1 Метод обратных взвешенных расстояний .....	7
1.1.2 Кrigинг .....	8
1.1.3 Интерполяция сплайном .....	9
1.1.4 ANUDEM .....	10
1.1.5 Полиномиальная интерполяция .....	11
1.1.6 Метод триангулированной нерегулярной сети .....	12
1.1.7 Метод радиально-базисной функции .....	13
1.2 Алгоритмы на основе машинного обучения .....	13
1.2.1 Заполнение пустот в цифровых моделях рельефа с использованием глубоких генеративных моделей .....	14
1.2.2 Интеграция топографических знаний в алгоритм на основе глубокого обучения для заполнения пустот цифровых моделей рельефа. ....	18
2. ПРОЕКТИРОВАНИЕ АЛГОРИТМА .....	23
2.1 Форматы цифровых моделей рельефа .....	23
2.2 Способы представления .....	26
2.3 Обзор доступных цифровых моделей рельефа .....	28
2.3.1 Типы карт высот .....	28
2.3.2 Сравнение наборов цифровых моделей рельефа .....	28
2.4 Обзор карт городских застроек .....	32
2.5 Выводы .....	34
2.6 Анализ архитектур GAN .....	35
2.7 Теоретическая схема алгоритма .....	38
2.8 Алгоритм подготовки данных .....	39
2.9 Критерии оценки эффективности .....	41
2.10 Подготовка данных .....	42

2.10.1 Визуальный анализ цифровых моделей поверхности.....	42
2.10.2 Наложение масок с городской застройкой .....	48
2.10.3 Интерполяция .....	50
3. РЕАЛИЗАЦИЯ АЛГОРИТМА .....	51
3.1 Обучение дискриминатора .....	52
3.2 Обучение генератора.....	53
3.3 Обучение WGAN.....	55
4. ТЕСТИРОВАНИЕ И АНАЛИЗ.....	57
4.1 Условия эксперимента .....	57
4.2 Результаты.....	58
ЗАКЛЮЧЕНИЕ .....	60
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ .....	63

## **СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ**

DEM (англ. Digital Elevation Model) – карта высот

DSM (англ. Digital Surface Model) – цифровая модель поверхности

DTM (англ. Digital Terrain Model) – цифровая модель рельефа

GAN – (англ. Generative Adversarial Network) генеративно-сопоставительная нейронная сеть

ГИС – географическая информационная система

ЦМР – цифровая модель рельефа

ЦМП – цифровая модель поверхности

Датасет – совокупность обработанных данных, систематизированных в определённом формате

ПО – программное обеспечение

## ВВЕДЕНИЕ

Цифровые модели рельефа (ЦМР) являются важным инструментом в различных научных дисциплинах, от геологии, географии, гидрологии до наук об окружающей среде, городского планирования и гражданского строительства. [1-5] Они обеспечивают трехмерное представление земной поверхности, что имеет решающее значение для процессов пространственного анализа, моделирования и принятия решений [6]. Однако качество и надежность этих моделей часто ухудшаются из-за наличия пробелов, искажений или отсутствия данных. [7]

При сканировании поверхности с помощью лидара, аэрофотографии или спутниковой фотографии и последующей фильтрации некорректных значений из облаков точек, возникают пустоты, которые необходимо заполнять [8]. Существуют различные методы решения вышеописанной проблемы. Алгоритмы, предполагающие совмещение различных источников данных эффективны, но требуют значительных временных и финансовых затрат, а традиционные алгоритмы интерполяции недостаточно точны и дают упрощенное представление о местности [9, 10]. Создание алгоритма, который позволил бы получать более точное представление о недостающих участках поверхности с использованием только имеющихся данных, позволит сократить временные и финансовые расходы на детализацию труднодоступных и урбанизированных участков местности. [10]

В результате предыдущей практической работы был подготовлен набор данных для обучения нейронной сети. Также были установлены параметры, требующие дополнительного исследования.




Рисунок 1. Цифровая модель рельефа.

Целью этой работы является реализация метода заполнения пустот в областях цифровых моделей рельефа с плотной городской застройкой на основе модели глубокого машинного обучения.

В процессе выполнения практики будут решены следующие задачи:

1. Определение архитектуры нейронной сети.
2. Реализация бэкенда для обучения модели на языке программирования Python с использованием фреймворка для машинного обучения PyTorch.
3. Обучение модели на ранее подготовленном наборе данных.
4. Проведение экспериментов с разрешением входных данных.

## 1. АНАЛИЗ СУЩЕСТВУЮЩИХ ПОДХОДОВ

Рассмотрим известные решения, их преимущества и недостатки.

### 1.1 Традиционные алгоритмы интерполяции

#### 1.1.1 Метод обратных взвешенных расстояний

Метод обратных взвешенных расстояний (англ. inverse distance weighting) основан на предположении, что близко расположенные объекты более похожи друг на друга, чем те, что находятся на удалении. В этом методе известные значения в окрестности точки используются для вычисления неизвестного значения. Считается, что влияние каждой измеренной точки на результат убывает с увеличением расстояния от неё. Высота в заданной точке определяется как взвешенное среднее значений высот точек в её окрестности, где веса зависят от обратного расстояния до этих точек [10, 11].

Значение возвышения в точке рассчитывается как усреднённое значение z-координат точек, расположенных в некоторой окрестности. Усреднение производится с учётом весовых коэффициентов, для которых определяется некоторая обратная функция расстояния.

Значение интерполируемой точки  $Z(s_0)$  рассчитывается как:

$$Z(s_0) = \sum_{i=1}^n \omega_i Z(s_i) = \sum_{i=1}^n Z(s_i) \frac{d_{io}^{-p}}{\sum_{i=1}^n \frac{1}{d_{io}^{-p}}} \quad (1)$$

где:

$\omega_i$  – вес известной опорной точки;

$p$  – показатель степени при определении веса опорной точки (обычно принимается равным 2);

$n$  – число опорных точек в окрестности  $s_0$ ;

$d_{io}$  – расстояние между опорной точкой и интерполируемой.

Метод интерполяции прост в применении и обладает сравнительно небольшой вычислительной сложностью. Область применения ограничивается небольшими локальными участками. Качество интерполяции сильно зависит от сложности рассматриваемой поверхности и в значительной мере от качества исходной цифровой модели рельефа. Метод чувствителен к выбросам.

### 1.1.2 Кригинг

Кригинг (англ. Kriging) относится к группе геостатистических методов интерполяции. Так же, как и в методе обратных взвешенных расстояний, каждой точке присваиваются вес в соответствии с расстоянием до неизвестного значения. Но в этом случае оценка формируется с учетом корреляции в исходных данных. Важную роль в результате интерполяции играют не только значения опорных точек, но и их расположение в пространстве. [12] В основу метода положен принцип несмещённости среднего. Это означает, что все вместе взятые на карте значения должны иметь правильное среднее значение. При этом за счёт повышения низких значений и уменьшения высоких обеспечивается глобальная несмещённость.

Основная формула схожа с методом обратных взвешенных расстояний и выглядит следующим образом:

$$Z(s_0) = \sum_{i=1}^n \omega_i Z(s_i), (2)$$

где:

$Z(s_i)$  – измеряемое значение в точке  $s_i$ ;

$\omega_i$  – неизвестный вес для измеряемого значения;

$s_0$  – точка, в которой производится интерполяция;

$n$  – число опорных точек.



Кригинг имеет высокую вычислительную сложность и требует выбора подходящей вариограммы для конкретного рельефа, что не всегда представляется возможным. Кроме того, необходимость предварительного анализа ландшафта для каждого рассматриваемого участка накладывает дополнительные требования на квалификацию пользователя. Метод генерирует качественные результаты, реализован в большинстве ГИС, часто применяется в научных статьях и в качестве эталона для более современных подходов к заполнению пустот в цифровых моделях рельефа.

### 1.1.3 Интерполяция сплайном

Интерполяция сплайном – детерминированный метод, который строит поверхность через опорные точки, сводя к минимуму её кривизну. Сплайн представляет собой функцию, которая определяется как кусочно-заданная и непрерывная, при этом каждый отдельный кусок формируется на основе простых функций, соответствующих определенным контрольным точкам. Чаще всего сплайны являются гладкими функциями, для которых в качестве фрагментов используют алгебраические полиномы. [13]

Так как сплайн является совокупностью функций, каждая из которых задана на своём подмножестве значений аргумента, то сплайн  $S(x)$  в общем случае можно записать следующим образом:

$$S(x) = \sum_{i=0}^N \alpha_i * \psi_i(x) + R(x),$$

где:

$\alpha_i$  – коэффициенты, зависящие от значений исходной функции  $f(x)$  в контрольных точках  $x$ ;

$\psi_i(x)$  – базисные функции сплайна;

$R(x)$  – некоторые регулирующие добавки.

По мерности пространства сплайны делятся на одномерные и двумерные. В первом случае сплайн является кривой, а во втором – поверхностью.

Обычно, при создании двумерных сплайнов в качестве области определения применяется прямоугольная сетка, где узлы сетки задаются с помощью контрольных точек. В таких условиях, конструкция двумерного сплайна, известного как бисплайн, может быть осуществлена путем умножения одномерных сплайнов для каждой переменной:

$$S(x, y) = \sum_{i=0}^{n_x} \sum_{j=0}^{n_y} f(x_i, y_j) * \psi_i^x(x) * \psi_j^y(y)$$

Метод прост в использовании, обладает низкой вычислительной сложностью. Выдаёт грубый оценочный результат. Не подходит для заполнения пустот в цифровых моделях рельефа сложной местности, так как не учитывает мелкие детали. Ещё одним недостатком данного метода является его неустойчивость к выбросам.

#### 1.1.4 ANUDEM

Метод ANUDEM представляет собой эффективную процедуру интерполяции цифровых моделей рельефа с регулярной сеткой. Он учитывает эрозионные свойства воды и строит связные дренажные системы рек и озёр [14]. Метод также может учитывать изолинии, береговые линии и линии обрывов.

Алгоритм обеспечения дренажа устраняет одну из основных слабых сторон цифровых моделей рельефа, созданных методами интерполяции общего назначения [15]. С помощью ANUDEM можно получить достаточно точные и естественные модели поверхности.

Метод обладает высокой вычислительной эффективностью, характерной для методов локальной интерполяции, таких как интерполяция методом обратных взвешенных расстояний, при этом сохраняется непрерывность поверхности, которая обычно наблюдается при применении методов глобальной интерполяции, включая Кригинг и Сплайн. [16].

#### 1.1.5 Полиномиальная интерполяция

Полиномиальная интерполяция — это метод численного анализа, который используется для нахождения полинома, который проходит через заданный набор точек данных. Этот полином можно использовать для аппроксимации функции, основанной на этих данных, или для предсказания новых значений. Этот вид интерполяции может быть использован только для грубой оценки рельефа большого участка земной поверхности с низким разрешением сканирования или отдельных небольших участков с плавно изменяющейся поверхностью [17].

В результате интерполяции получается поверхность, которая проходит только через некоторые опорные точки, что делает этот метод нежестким методом интерполяции.

В отличие от метода глобального полинома, который использует один полином для всех точек, интерполяция с использованием локальных полиномов выбирает несколько полиномов, причем каждый из них адаптирован к конкретной окрестности точек. Таким образом формируются сложные полиномиальные плоскости, которые позволяют представлять комплексные ландшафты с часто изменяющейся формой, например с чередованием склонов и ровных поверхностей. [18]

### 1.1.6 Метод триангулированной нерегулярной сети

Метод интерполяции на основе триангулированной нерегулярной сети (англ. Triangulated Irregular Network) известный также как триангуляция Делоне, представляет собой способ создания сетки из треугольников на основе заданного набора точек на плоскости или в трёхмерном пространстве. Этот метод широко используется в геодезии, картографии, геоинформационных системах и в других областях, где необходимо провести интерполяцию, аппроксимацию или моделирование поверхностей.

Основная идея метода триангулированной нерегулярной сети заключается в том, что каждая пара точек в наборе соединяется отрезком, образуя рёбра, и затем эти рёбра разбивают плоскость на треугольники. При этом выполняется условие критерия Делоне: для каждого треугольника в сетке окружность, проходящая через все три вершины треугольника, не должна содержать других точек набора внутри себя. Этот критерий обеспечивает оптимальное разбиение плоскости на треугольники, минимизируя остроугольные треугольники и обеспечивая равномерность сетки.

Метод триангулированной нерегулярной сети широко применяется в компьютерной графике для построения трёхмерных моделей, генерации сеток для алгоритмов конечных элементов, создания цифровых моделей местности и многих других приложений, где требуется работа с геометрическими данными.

### 1.1.7 Метод радиально-базисной функции

Радиально-базисной называется функция  $F(s, t)$ , которая зависит только от расстояния между точками  $s$  и  $t$ . То есть  $s, t \in \mathbb{R}^d$   $\Phi(s, t) = \phi(|s - t|)$  где  $|s - t|$  – Евклидово расстояние между точками  $s$  и  $t$ .

Радиальные базисные функции относятся к группе методов точной интерполяции [9,19]. Интерполируемая поверхность, создаваемая с их помощью, обязательно проходит через каждую опорную точку. Перечень основных типов радиально-базисных функций:

- Плоский сплайн
- Сплайн с натяжением
- Полностью регуляризованный сплайн
- Функция мультиквадриков
- Функция обратных мультиквадриков

В отличие от метода интерполяции обратных взвешенных расстояний, радиально-базисные функции могут интерполировать значения, превышающие максимальное или не достигающие минимального из измеренных значений.

Радиальные базисные функции используются для создания гладких поверхностей из дискретных наборов точек. С их помощью можно создавать незначительно изменяющиеся поверхности. Методы не могут быть использованы при существенных изменениях значений поверхности в пределах небольших расстояний.

## 1.2 Алгоритмы на основе машинного обучения

Увеличение вычислительных мощностей за последние два десятилетия привело к развитию идеи применения нейронных сетей для решения различных научных и бытовых задач. Алгоритмы на основе глубоких

нейронных сетей применяются для решения задач классификации объектов на изображениях, нахождения скрытых зависимостей в наборах немаркированных данных, обнаружения преступлений путём анализа данных камер видеонаблюдения в реальном времени, синтеза и анализа речи и текста, создания автопилота, игры в шахматы, шашки, сёги, го и даже Starcraft.

Принципиально новый нейросетевой подход к решению научных задач успел зарекомендовать себя с лучшей стороны в смежных областях. Как следствие, появились исследования возможности применения алгоритмов глубокого машинного обучения для устранения недостатков цифровых моделей рельефа.

#### 1.2.1 Заполнение пустот в цифровых моделях рельефа с использованием глубоких генеративных моделей

Генеративные модели относятся к ветви методов обучения без учителя, которые оценивают распределение вероятностей, лежащее в основе исходных данных. Изучить это распределение в явном виде для сложных многомерных вероятностных распределений, например, для генерации данных ЦМР – невозможно. Однако можно получить неявное описание с помощью модели, способной генерировать выборки из оценочного распределения.

Генеративно-сопоставительные сети представляют собой многообещающую основу для обучения модели, способной генерировать подобные образцы. Одна из причин заключается в том, что сопоставительные потери в GAN улавливают характерные особенности, которые не удаётся зарегистрировать с помощью среднеквадратичной ошибки [20].

Генеративно-сопоставительная сеть – это алгоритм машинного обучения без учителя, построенный на комбинации двух нейронных

сетей: генератора и дискриминатора. Генератор создаёт новые экземпляры данных, которые должны быть похожи на реальные, а дискриминатор определяет, относится ли каждый экземпляр данных, который он рассматривает, к набору тренировочных данных или нет, то есть устанавливает подлинность образца.

В своём исследовании авторы применили архитектуру нейронной сети, которая изображена на рисунке 2.




Рисунок 2. Генеративная модель заполнения пустот в ЦМР.

Использованный в исследовании алгоритм представлен на рисунке 3.

---

**Algorithm 1** DEM Void Filling

---

**Input:** *partial DEM*  $\mathbf{D}^0 = (d_p^0)$ , *mask*  $\mathbf{M} = (m_p)$   
*blending weight function*  $\beta$ , *blending width*  $w$   
*paraboloid fitting window radius*  $r$

**Output:** *predicted DEM*  $\mathbf{D}$

- 1:  $\mathbf{D} \leftarrow G(\mathbf{D}^0, \mathbf{M})$   $\triangleright$  *initial result*
- 2: partition unknown pixels to sets  $R_k$  of pixels  
with  $L_1$  distance of  $k$  from a known pixel
- 3: **for**  $k \leftarrow 1, \dots, w$  **do**
- 4:   **for**  $p = (i, j) \in R_k$  **do**
- 5:     compute the set  $X$  of known pixels of  $\mathbf{D}^0$   
in subgrid  $[i - r, i + r] \times [j - r, j + r]$
- 6:     perform least squares paraboloid fitting to  $X$   
 $f^* \leftarrow \operatorname{argmin}_f \sum_{q \in X} [f(q) - d_q]^2$
- 7:      $d_p^0 \leftarrow f^*(p)$   $\triangleright$  *approximate  $C^2$  extension of  $\mathbf{D}^0$*
- 8:      $\alpha \leftarrow \beta(\frac{k-1}{w})$   $\triangleright$  *blending weight*
- 9:      $d_p \leftarrow (1 - \alpha) d_p^0 + \alpha d_p$   $\triangleright$  *blend*
- 10:   **end for**
- 11:    $m_{R_k} \leftarrow 0$   $\triangleright$  *label pixels in  $R_k$  as known*
- 12: **end for**

---

Рисунок 3. Алгоритм заполнения пустот в ЦМР на основе генеративно-состязательной нейронной сети.

В результате проделанной работы авторы получили алгоритм, который качественно превосходит традиционные методы интерполяции. Он показывает сравнимый результат на ЦМР сельской местности и значительно более точный в городской местности [21], что хорошо видно на рисунках 4, 5 и 6.






Рисунок 6. Неудачный тест заполнения пустот на ЦМР городской местности. (Слева направо) Исходная ЦМР, маска, интерполяция сплайном, метод обратных взвешенных расстояний, GAN.



Рисунок 5. Результат заполнения пустот на ЦМР сельской местности. (Слева направо) Исходная ЦМР, маска, интерполяция сплайном, метод обратных взвешенных расстояний, GAN.




Рисунок 4. Результат заполнения пустот на ЦМР городской местности. (Слева направо) Исходная ЦМР, маска, интерполяция сплайном, метод обратных взвешенных расстояний, GAN.

Из недостатков можно выделить синтетическую маску, которую накладывали на исходные данные [22]. В реальных задачах пустоты представляют собой области с разреженными кластерами точек, а не фигуры правильной формы, внутри которых точки полностью отсутствуют. Также следует отметить отсутствие каких-либо наложенных ограничений, что приводит к неудачному эксперименту в городской местности с выделяющимся дорожным покрытием.

### 1.2.2 Интеграция топографических знаний в алгоритм на основе глубокого обучения для заполнения пустот цифровых моделей рельефа

Интеграция вспомогательных цифровых моделей рельефа из других источников является возможным способом заполнения пустот в целевых ЦМР. Например, модели ASTER GDEM V2 и GMTED2010 были использованы для заполнения пустот в Shuttle Radar Topography Mission 2021. [23] Однако, такой подход сопряжён с некоторыми трудностями. Обычно сочетание нескольких ЦМР приводит неравномерному качеству в областях сопряжения. Кроме того, вспомогательные ЦМР не всегда доступны в областях с пустотами, что также ограничивает применение такого рода методики.

Некоторые методы интерполяции, такие как кригинг, сплайн и метод обратных взвешенный расстояний, широко применяются в географических исследованиях в качестве возможного метода заполнения пустот и показали хорошие результаты в конкретных случаях [23,24]. Характеристики рельефа вокруг пустот оказывают существенное влияние на качество результатов применения методов интерполяции. Ввиду редкости опорных точек в областях с пустотой, наблюдается тенденция к генерации несогласованных границ на стыках пустоты с окружающей ЦМР.

Топографические знания представляют собой семантические описания топографических характеристик в различных средах. Например, долина характеризуется тальвегом, а гора — вершиной.

При реконструкции ЦМР необходимо делать упор на топографические знания, потому что общие ограничения на уровне пикселей могут быть неэффективными при заполнении пустот достоверным рельефом. Например, как показано на рисунке, хотя оба

они имеют одинаковые с среднеквадратические ошибки, рельефы, представленные этими двумя рисунками, не следует рассматривать как одинаковые из-за разных уклонов. и направлений хребта. Это указывает на возможность реконструкции ЦМР с хорошей точностью на уровне пикселей, но при этом получить некорректный ландшафт.

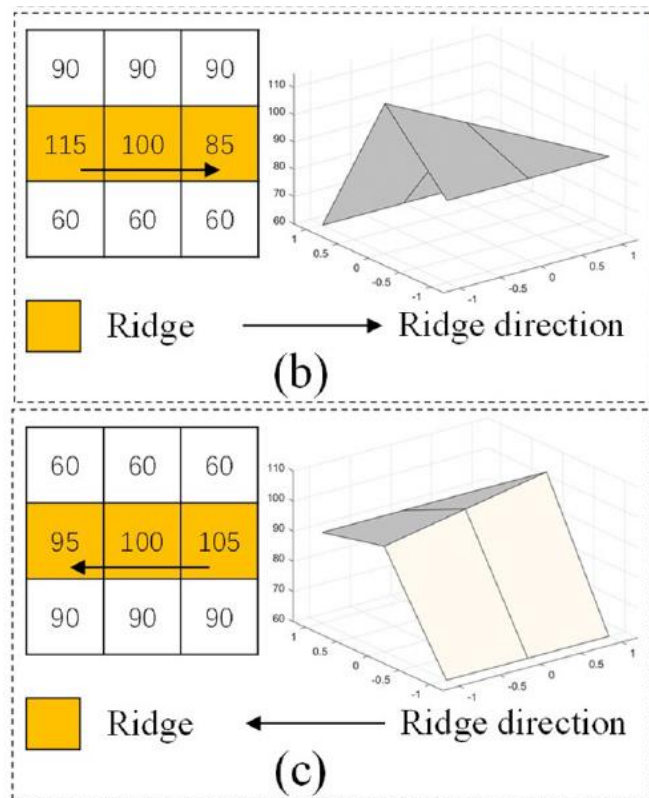


Рисунок 7. Полученные разными методами результаты реконструкции.

Авторы применяют GAN, схема которого изображена на рисунке 8.

В процессе обучения они накладывают на входные данные ограничения

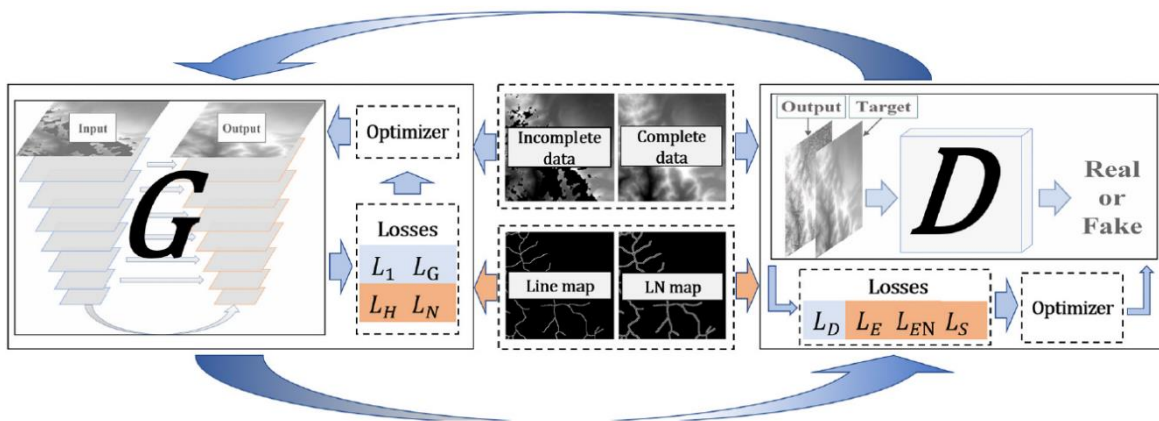


Рисунок 8. Структура генеративно-состязательной нейронной сети TKGANN.

в виде топографически корректных линий хребтов и дна рек. [25] Пример представлен на рисунке 9.

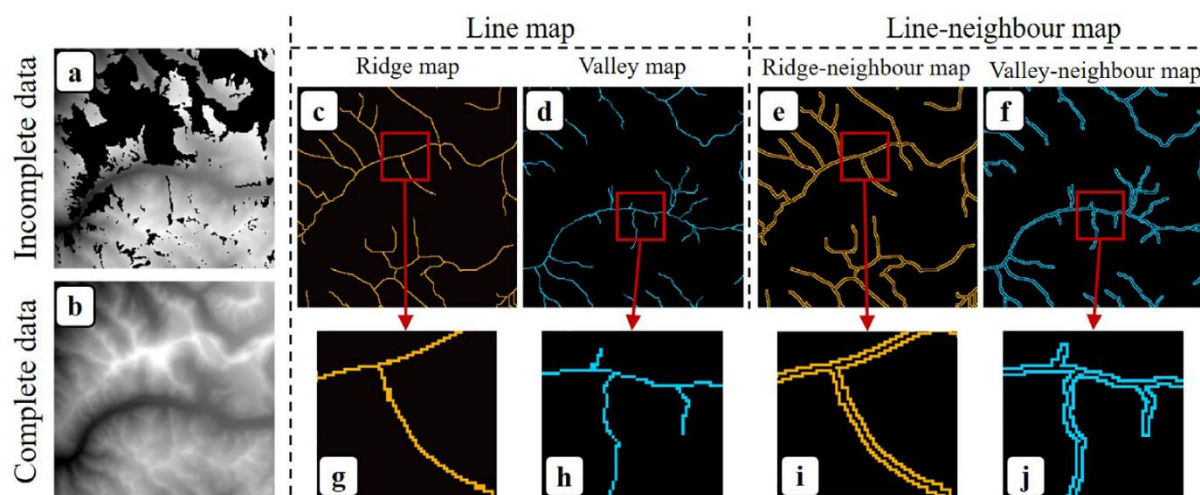


Рисунок 9. Представления различных наборов данных, используемых в TKCGAN (образцы Гималаев). а – неполные данные. b – полные данные; (c) – (f) – карта хребта, карта долины, карта соседних точек хребта, карта соседних точек в долине. Увеличенные изображения красных квадратов на рисунках (c) – (f).

Авторы исследования попытались интегрировать фундаментальные топографические знания в процесс реконструкции цифровых моделей рельефа и построить основанную на глубоком обучении модель под названием TKCGAN. TKCGAN использует характерные линии рельефа в качестве дополнительных входных данных и обучается топографическим характеристикам на основе этих входных признаков.

Топографические данные о долинах и хребтах переформулированы так, чтобы установить новые функции потерь, которые позволяют нейросети заполнять пустоты более корректным рельефом.

Сравнение показывает, что TKCGAN превосходит традиционные методы интерполяции и CGAN [22], особенно в отношении нахождения корректного направления уклона. Кроме того, полученный алгоритм повышает точность высот и уклонов поверхности и улучшает реконструируемую ЦМР.

Предложенная стратегия может заполнять пустоты в ЦМР с разным пространственным разрешением и разного размера. Авторы отмечают, что в будущем этот подход можно адаптировать для решения задач в связанных исследованиях и на рельефах местности другого рода.

## 2. ПРОЕКТИРОВАНИЕ АЛГОРИТМА

### 2.1 Форматы цифровых моделей рельефа

#### ASCII

В этом формате данные о высоте хранятся в виде текстового файла, где каждая строка представляет точку на сетке и значение высоты в этой точке.

#### GeoTIFF

Данные о высоте в GeoTIFF хранятся в виде растрового изображения, где каждый пиксель представляет определенное значение высоты. Значения высоты обычно получаются на основе данных дистанционного зондирования или топографических съемок и могут использоваться для создания цифровых моделей местности. Формат GeoTIFF позволяет хранить метаданные, такие как информация о системе координат, детали проекции и разрешение пикселей, которые важны для точного анализа и визуализации данных о высоте. Некоторые файлы GeoTIFF также могут содержать несколько слоёв данных, таких как уклон или экспозиция, которые предоставляют дополнительную информацию о местности.

#### ESRI Grid format

Формат ESRI Grid — это формат растровых данных, разработанный ESRI, ведущим поставщиком программного обеспечения ГИС. Он хранит пространственные данные в виде сетки ячеек, где каждая ячейка представляет определенное значение или атрибут. Формат ESRI Grid обычно используется для хранения данных о высоте, данных о растительном покрове и других типах пространственных данных, которые могут быть представлены в виде непрерывной поверхности. Формат позволяет хранить метаданные, такие как информация о системе координат, детали проекции и размер ячейки, которые важны для точного анализа и визуализации данных.

#### GTOR30

Формат GTOPO30 — это формат растровых данных, разработанный Геологической службой США (USGS) для хранения глобальных данных о высоте. Он назван в честь «Global 30 Arc-Second Elevation Data Set» (GTOPO30), который представлял собой глобальную цифровую модель рельефа, созданную Геологической службой США в 1990-х годах. Формат GTOPO30 хранит данные о высоте в виде сетки ячеек, где каждая ячейка представляет значение высоты в определенном месте на поверхности Земли. Этот формат обычно используется для различных приложений, включая гидрологическое моделирование, анализ местности и визуализацию.

#### SRTM

Формат SRTM — это формат растровых данных, разработанный Национальным управлением по авиации и исследованию космического пространства США для хранения глобальных данных о высоте. Он назван в честь «Shuttle Radar Topography Mission» (SRTM), которая представляла собой миссию, выполненную в 2000 году для сбора радиолокационных данных для создания цифровой модели рельефа поверхности Земли с высоким разрешением. Формат SRTM хранит данные о высоте в виде сетки ячеек, где каждая ячейка представляет значение высоты в определенном месте на поверхности Земли. Этот формат обычно используется для различных приложений, включая топографическое картографирование, планирование землепользования и моделирование климата.

#### NetCDF

NetCDF (англ. Network Common Data Form) — это формат файлов, используемый для хранения и обмена научными данными. Он не зависит от устройства, что упрощает обмен данными между различными компьютерными системами и программными приложениями. Файлы NetCDF могут хранить различные типы научных данных, включая метеорологические, океанографические и климатические данные, в массивах или сетках, включая



метаданные для описания переменных и их атрибутов. Доступ и управление им можно осуществлять с помощью различных языков программирования, включая Python, MATLAB и R, и он обычно используется в исследованиях и научных приложениях.

В дальнейшей работе будут рассматриваться ЦМР в формате GeoTIFF, так как он наиболее удобен для создания и хранения набора данных и позволяет редактировать модель с помощью программных библиотек обработки изображений и производить визуальный анализ результатов без дополнительного ПО.

## 2.2 Способы представления

### 3D

Одним из наиболее распространенных методов визуализации цифровых моделей рельефа является использование программного обеспечения для 3D-визуализации, такого как ArcGIS, QGIS или Google Earth. Это позволяет просматривать данные о высоте в 3D, что может помочь выявить закономерности и особенности, которые могут быть не видны на двумерной карте.

#### Карты горизонталей

Карта горизонталей — это тип карты, которая отображает высоту территории с помощью линий, которые соединяют точки одинаковой высоты. Линии обычно изображаются через равные промежутки, например, каждые 10 футов или каждые 100 метров. Чем ближе друг к другу горизонтали, тем круче рельеф. Карты горизонталей можно использовать для отображения формы и особенностей местности, таких как холмы, долины и хребты, и они обычно используются в геологии, географии и технике для изучения топографии и планирования строительных проектов.

#### Карты уклонов

Карта уклона — это тип карты, которая показывает крутизну местности с использованием разных цветов или штриховок для обозначения различных степеней уклона. Карты уклонов создаются путем расчета изменения высоты между соседними точками на цифровой модели рельефа и последующего назначения цветов или оттенков каждой категории уклона. Карты уклонов могут быть полезны для определения областей, склонных к оползням или эрозии, а также для планирования пешеходных или велосипедных маршрутов, избегающих чрезмерно крутой местности. Они широко используются в геологии, географии и науке об окружающей среде.

## Карты аспектов

Карта аспектов — это тип карты, которая показывает направление склона, например север, юг, восток или запад. Карты аспектов создаются путем анализа наклона местности и определения направления склона. Эту информацию можно использовать для определения областей, которые получают больше или меньше солнечного света, что может повлиять на рост растительности и наличие воды. Карты аспектов обычно используются в сельском хозяйстве, лесном хозяйстве и землепользовании, чтобы помочь принимать решения о землепользовании и управлении ресурсами.

## 3D Печать

Другой способ визуализации цифровых моделей рельефа — создать физическую модель с использованием технологии 3D-печати. Это может быть полезно для детального изучения местности и выявления особенностей, которые могут быть не видны в цифровом представлении.

## 2.3 Обзор доступных цифровых моделей рельефа

Для проведения экспериментов по заполнению пустот в областях ЦМР с плотной городской застройкой был произведен анализ доступных наборов данных и выбран наиболее подходящий датасет.

### 2.3.1 Типы карт высот

Карты высот подразделяются на цифровые модели поверхности (DSM) и цифровые модели рельефа (DTM). DSM получают путём применения различных методов сканирования поверхности земного шара, таких как лидар, аэрофотография, стереофотограмметрия и др. Такие модели включают в себя не только рельеф планеты, но и все объекты на её поверхности: сооружения, растительность. DTM же напротив является моделью рельефа без сооружений и растительности, получают её фильтрацией DSM и заполнением образовавшихся пустот с помощью одного из методов интерполяции. [7] Отличия DSM и DTM наглядно представлены на рисунке 10.




Рисунок 10. Иллюстрация отличий DSM и DTM.

Так как целью работы является заполнение пустот в областях с плотной городской застройкой, далее будут рассматриваться преимущественно DSM.

### 2.3.2 Сравнение наборов цифровых моделей рельефа

Для применения подхода на основе машинного обучения, было необходимо подобрать датасет с наибольшим количеством областей с плотной городской застройкой и максимально высоким разрешением. Результат

анализа представлен в таблице 1. Часть источников данных в таблице отсутствует, так как некоторые из найденных наборов ЦМР являются производными улучшенными вариантами на основе более старых наборов данных.

<b>Набор данных</b>	<b>Тип модели</b>	<b>Способ получения</b>	<b>Вертикальная точность, м</b>	<b>Горизонтальная точность, м</b>	<b>Зона покрытия</b>
Shuttle Radar Topography Mission (SRTM)	DSM	Радиолокационная интерферометрия из космоса	16	30	Весь мир между 60 градусам и северной широты и 56 градусам и южной широты.
Advanced Spaceborne Thermal Emission and Reflection Radiometer (ASTER)	DSM	Стереоскопическая корреляция оптических изображений	20	30	Весь мир между 83 градусам и северной широты и 83 градусам и южной широты.

USGS National Elevation Dataset (NED)	DSM	Комбинация множества датасетов в том числе: данные LiDAR, SRTM	3	10	Вся территор ия США
Global Multi- resolution Terrain Elevation Data 2010 (GMTED20 10)	DSM	Комбинация различных источников данных, включая SRTM, ASTER и LiDAR	7	230 м – 1 км	Весь мир между 83 градусам и северной широты и 83 градусам и южной широты.
JAXA's Global ALOS 3D World	DSM	Стереоскопическа я корреляция оптических изображений	5	30	Весь мир между 83 градусам и северной широты и 83 градусам и южной широты
COPERNIC US GLO-30	DSM	Sentinel-2	5	20	Весь мир между 85

		Мультиспектральные сенсоры			градусам и северной широты и 60 градусам и южной широты
TanDEM-X	DSM	Радиолокационная интерферометрия из космоса.	2	12	Весь мир

Таблица 1. Сравнительная таблица DEM с мировым охватом.

## 2.4 Обзор карт городских застроек

Для решения задачи фильтрации сооружений от поверхности рельефа, было необходимо подобрать источники данных о застройке. Существует несколько датасетов, которые содержат такие сведения.

OpenStreetMap (OSM) — это совместный картографический проект с открытым исходным кодом, целью которого является создание бесплатной и редактируемой карты мира. OSM предоставляет подробную информацию о дорогах, зданиях, достопримечательностях и других объектах, а также географические данные, такие как высота над уровнем моря и водные пути. Данные собираются с помощью GPS-устройств, аэрофотоснимков и других источников, а затем загружаются в базу данных OSM. Пример карты OpenStreetMap представлен на рисунке 11.



Рисунок 11. Изображение княжества Монако на карте OpenStreetMap.



World Settlement Footprint (WSF) — это глобальный набор данных, который предоставляет информацию о местоположении и размерах населенных пунктов на поверхности Земли. Он создается путем анализа спутниковых изображений и других источников данных для определения районов, где люди живут и работают. Набор данных WSF включает информацию о зданиях, дорогах и других сооружениях, а также плотность населения и другую демографическую информацию. Пример карты WSF представлен на рисунке 12.




Рисунок 12. Изображение княжества Монако на карте WSF.

## 2.5 Выводы

Наборы данных SRTM и ASTER не подходят для решения поставленной задачи, так как они являются устаревшими и их точность достаточно мала. Набор NED значительно точнее большинства глобальных датасетов и является достаточно современным, поэтому может быть применён для проведения экспериментов, однако покрывает только территорию США поэтому будет использован для составления гибридного набора данных. Отдельный интерес представляет датасет TanDEM-X, который обладает наибольшей точностью, но доступ к нему ограничен, поэтому он не может быть использован в дальнейших исследованиях. Точность датасетов ALOS 3D и Copernicus разнится в зависимости от рассматриваемой местности, поэтому в экспериментах будут использоваться оба.

## 2.6 Анализ архитектур GAN

Последние исследования в области машинного обучения показывают, что модели на основе генеративно-состязательных нейронных сетей могут быть использованы для решения различных задач, таких как: генерация изображений, воссоздания стиля, синтез текста в изображение, дополнение данных и повышение разрешения. Значительные успехи в задачах генерации изображений и дополнения данных позволяют говорить о возможности использования такого вида нейронной сети для фильтрации зданий в цифровых моделях поверхности с последующим заполнением пустот.

В опубликованных исследованиях предпринимались попытки использовать генеративно-состязательные нейронные сети для заполнения пустот в цифровых моделях рельефа. Некоторые подходы на основе машинного обучения показали сравнимые результаты в большинстве случаев и превосходили традиционные алгоритмы интерполяции в определённых сценариях. Алгоритмы на основе GAN ранее не применялись для решения задачи фильтрации сооружений и растительности в цифровых моделях поверхности, поэтому важно подобрать оптимальную для решения задачи архитектуру. Анализ известных моделей GAN представлен в таблице 2.

Архитектура	Может быть использована для заполнения пустот	Применялась ранее	Год
StyleGAN	Нет	—	2018
BigGAN	Да	Нет	2018
Self-Attention GAN (SAGAN)	Нет	—	2018
Progressive Growing of	Да	Нет	2017

GAN (ProGAN)			
CycleGANs	Да	Нет	2017
Wasserstein GAN (WGAN)	Да	Да	2017
InfoGAN	Нет	—	2016
Pix2Pix	Да	Нет	2016
StackGAN	Нет	—	2016
StarGAN	Нет	—	2016
Text-to-Image GAN	Нет	—	2016
Super Resolution GAN (SRGAN)	Да	Нет	2016
Deep Convolutional GAN (DCGAN)	Да	Да	2015
Conditional GAN (cGAN)	Нет	—	2014

Таблица 2. Сравнительная таблица архитектур генеративно-состязательных нейронных сетей.

Среди перечисленных выше архитектур наибольший интерес представляют BigGAN [21], ProGAN [22] и Wasserstein GAN [23]. Известно, что BigGAN и ProGAN требуют значительных вычислительных мощностей, поэтому

возможность их применения в дальнейших исследованиях остаётся под вопросом. WGAN интересен ещё и тем, что ранее применялся для решения задачи заполнения пустот в областях со сложным горным рельефом и превзошёл традиционные методы интерполяции в некоторых случаях. Определить оптимальную архитектуру и гиперпараметры заранее невозможно, это будет сделано в дальнейших экспериментах.

## 2.7 Теоретическая схема алгоритма

К реализации предлагается алгоритм фильтрации зданий с поверхности DEM с последующим заполнением пустот на основе модели генеративно-состязательной нейронной сети, который представлен на рисунке 13. Обучение GAN предполагает одновременное обучение двух нейронных сетей: генератора и дискриминатора. Генератор создает новые данные, похожие на исходные, а дискриминатор пытается отличить сгенерированные данные от реальных. Для этого необходимо подготовить два датасета с данными: исходный и целевой. В качестве исходного набора предлагается использовать базы ALOS 3D, Copernicus и NED. Целевой набор представляет собой цифровую модель рельефа без строений. Так как существуют цифровые модели рельефа только для отдельных относительно небольших участков поверхности земного шара, а для эффективного обучения нейронной сети необходимо достаточно большое количество данных, предлагается создать целевой датасет вручную.




Рисунок 13. Общая схема работы алгоритма.

## 2.8 Алгоритм подготовки данных

Первым шагом необходимо создать датасет областей цифровых моделей поверхности с плотной городской застройкой из трёх выделенных выше наборов. Затем необходимо нанести из WSF и OSM данные о застройке и отфильтровать выделенные точки.

После этого необходимо заполнить получившиеся в исходных данных пустоты с применением алгоритмов интерполяции Kriging[11], LR B-Spline [12, 14, 15] или моделей на основе глубокого машинного обучения, которые рассматривались в предыдущей работе [16, 17]. Это позволит получить целевой набор данных для обучения обеих нейросетей. Схема процесса подготовки данных для обучения генеративно-сопоставительной нейронной сети представлена на рисунке 14.



Рисунок 14. Схема подготовки данных для обучения нейросети.



## 2.9 Критерии оценки эффективности

Существует несколько способов оценки эффективности работы алгоритмов интерполяции. Одним из них является визуальный анализ, который предполагает визуальное сравнение интерполированной поверхности с исходными данными и оценку того, насколько хорошо она отражает особенности и закономерности в них. Такая оценка может быть субъективной, но может дать ценную информацию о сильных и слабых сторонах, а также об ограничениях различных алгоритмов [20].

Также на практике применяются следующие метрики:

- Средняя ошибка (ME)
- Стандартное отклонение (SD)
- Среднеквадратическая ошибка (MSE)
- Средняя абсолютная ошибка (MAE)

Все вышеперечисленные метрики будут использованы в дальнейшей работе для сравнения полученных результатов с имеющимися цифровыми моделями рельефа городов, полученными с помощью лидара, там, где это возможно, или с синтетическими моделями, полученными в процессе подготовки датасета для обучения нейросети.

## **2.10 Подготовка данных**

### **2.10.1 Визуальный анализ цифровых моделей поверхности**

На первом этапе подготовки базы обучающих изображений был произведён предварительный визуальный анализ исходных данных цифровых моделей поверхности, так-как до этого исследование опиралось преимущественно на значения точности, которые были предоставлены авторами наборов данных.

В рамках реализации проекта было принято решение использовать географическую информационную систему Quantum GIS (QGIS), которая является программным обеспечением с открытым исходным кодом. Этот инструмент предоставляет широкие возможности для работы с пространственными данными, включая их создание, редактирование, анализ и визуализацию, что делает его особенно полезным для целей исследования. Кроме того, QGIS имеет Python API, что позволяет автоматизировать процессы работы с данными и обеспечивать бесшовный обмен с другими программными решениями, что будет полезно для дальнейшей работы, так-как для обучения нейросети планируется использовать Python совместимый бэкэнд.

Пример базовой карты местности в программе QGIS представлен на рисунке 15.




Рисунок 15. Карта города Нижний Новгород в QGIS.

Далее в проект были импортированы данные цифровых моделей поверхности Copernicus, ALOS 3D и National Elevation Dataset. Рассмотрим отдельные участки некоторых из них.

На рисунках 5 и 6 представлены результаты наложения ЦМП на базовую карту на примере того же участка города Нижний Новгород, что и на рисунке 16. Визуальный анализ в среднем масштабе 1:30000 не оставляет сомнений в том, что набор ALOS 3D содержит больше деталей. Четко видны границы отдельных зданий. Соседние строения не сливаются в неразличимую массу, четко выделены проезжие части, границы кварталов, видны фрагменты мостов.




Рисунок 17. Нижний Новгород на цифровой модели поверхности Copernicus.




Рисунок 16. Нижний Новгород на цифровой модели поверхности ALOS 3D.

Рассмотрим более сложный, с точки зрения получения цифровых моделей поверхности участок, для этого переместимся на север, в Мурманск. Сравнительный анализ цифровой модели поверхности Copernicus и ALOS 3D для вышеописанного участка представлен на рисунках 18 и 19.




Рисунок 18. Мурманск на цифровой модели поверхности Copernicus.




Рисунок 19. Мурманск на цифровой модели поверхности ALOS 3D.

В случае с северным районом, где спутниковые снимки обычно подвергаются наибольшему искажению, ALOS 3D оказался менее точным. С одной стороны, на поверхности ALOS 3D видны очертания порта, которых на Copernicus нет. С другой стороны, наблюдаются множественные искажения, шум и выбросы: на изображении есть две крупные яркие области, которые соответствуют возвышенности и сильно выбиваются из общего ландшафта города. Южное пятно находится на территории Мурманской ТЭЦ, спутниковый снимок которой представлен на рисунке 20. Столь высокая яркость в этой области, скорее всего, отражает высоту дымовых труб, чья высота значительно больше средней по городу. Однако, область слишком большая, перекрывает площадь всей ТЭЦ, и является ошибкой в данных.





Рисунок 20. Мурманская ТЭЦ, вид со спутника.

В наборе Copernicus дымовые трубы тоже присутствуют в виде маленького светлого пятна, но увидеть их можно только значительно увеличив масштаб. Таким образом можно сделать вывод, что изначальное решение применять оба источника цифровых моделей поверхности было верным.

### 2.10.2 Наложение масок с городской застройкой

Следующим этапом в проект были добавлены данные Open Street Map и World Settlement Footprint. Исходные данные с наложенными масками зданий представлены на рисунках 21 и 22.



Рисунок 21. Данные ALOS 3D с наложенной маской WSF.





Рисунок 22. Данные ALOS 3D с наложенной маской OSM.

### 2.10.3 Интерполяция

В результате интерполяции замаскированных областей, были получены фрагменты ЦМР без зданий. Примеры изображений до и после преобразований представлены на рисунках 23 и 24.




Рисунок 24. Исходная ЦМР.



Рисунок 23. Результат обработки.

### 3. РЕАЛИЗАЦИЯ АЛГОРИТМА

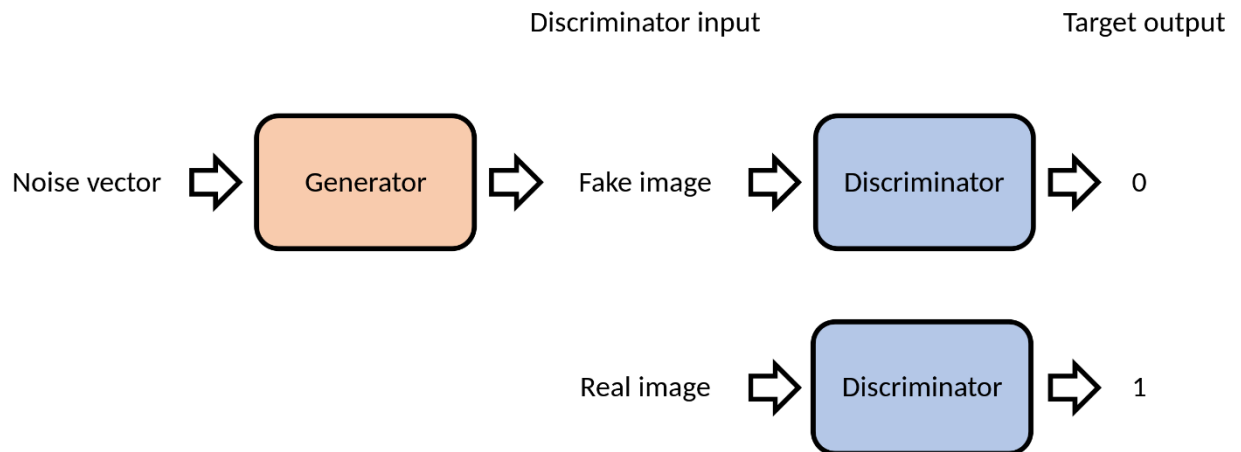


Рисунок 25. Общая схема GAN.

В общем случае генеративно-состязательная нейронная сеть представляет собой комбинацию из двух моделей глубокого машинного обучения: генератора и дискриминатора.

Генератор (G)– это компонент, который отвечает за создание новых выборок данных идентичных обучающим. В качестве входных данных он принимает случайный шум и генерирует образцы. Задача генератора состоит в том, чтобы производить искусственные данные, неотличимые для дискриминатора от настоящих.

Дискриминатор (D) представляет собой бинарный классификатор, который направлен на различение подлинных данных от фальшивых, сгенерированных генератором.

Подобные модели обучаются состязательным способом:

Генератор пытается улучшить способность производить реалистичные данные, сводя к минимуму способность дискриминатора различать реальные и сгенерированные образцы.

Дискриминатор пытается улучшить свою способность различать реальные и сгенерированные образцы, максимизируя точность классификации.

Общая схема модели представлена на рисунке 25.

### 3.1 Обучение дискриминатора

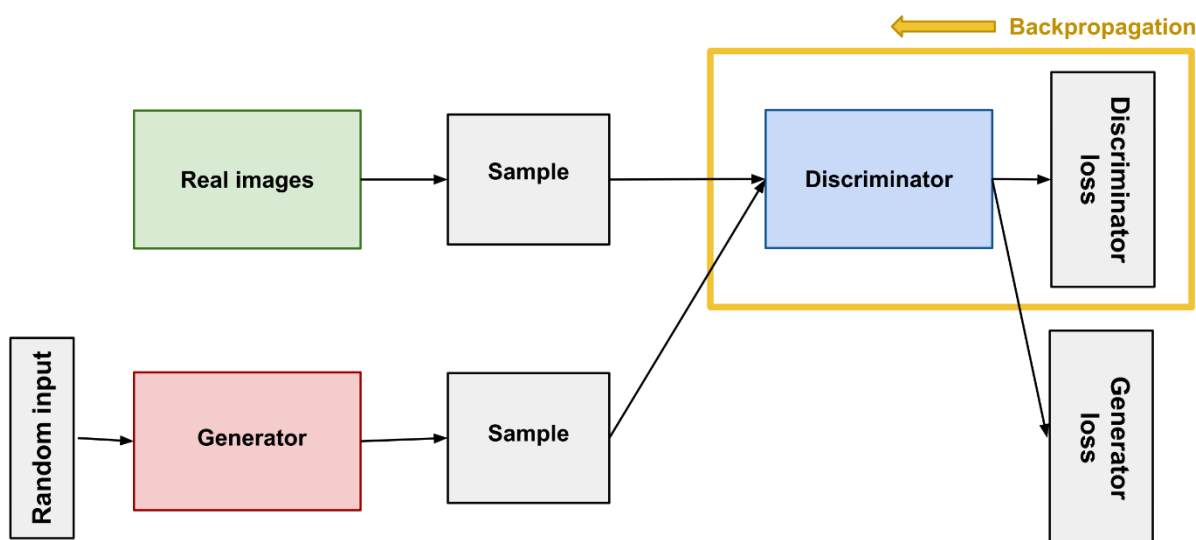


Рисунок 26. Схема обучения дискриминатора.

Для обучения дискриминатора используются данные из двух источников:

- Реальные выборки данных, в контексте текущей работы это фрагменты ЦМР с интерполированными пустотам от зданий.
- Поддельные выборки данных – это выборки, созданные генератором.

Дискриминатор подключается к двум функциям потерь. Но в процессе обучения дискриминатор использует только потери дискриминатора.

Процесс обучения дискриминатора состоит из следующих этапов:

1. Дискриминатор выполняет задачу классификации, определяя, какие из представленных ему данных являются настоящими, а какие сгенерированы генератором.



фрагменты цифровых моделей поверхности, которые должны быть преобразованы в цифровые модели рельефа без зданий).

- Нейронная сеть генератора, преобразующая входные данные в новый набор данных.
- Нейронная сеть дискриминатора, задача которой — оценить и классифицировать данные, созданные генератором.
- Результаты работы дискриминатора, которые указывают на качество сгенерированных данных.
- Функция потерь для генератора, необходимая для корректировки его работы через механизм обратного распространения ошибки. В данном эксперименте для оптимизации процесса применяется функция потерь Вассерштейна.

Эти элементы вместе формируют обучающую среду, в которой генератор стремится создать достоверные данные, а дискриминатор — точно их классифицировать, способствуя тем самым улучшению качества искусственно созданных изображений. Схема процесса обучения генератора представлена на рисунке 27.

### 3.3 Обучение WGAN

**Require:** :  $\alpha$ , the learning rate.  $c$ , the clipping parameter.  $m$ , the batch size.

$n_{\text{critic}}$ , the number of iterations of the critic per generator iteration.

**Require:** :  $w_0$ , initial critic parameters.  $\theta_0$ , initial generator's parameters.

```
1: while  $\theta$  has not converged do
2:   for  $t = 0, \dots, n_{\text{critic}}$  do
3:     Sample  $\{x^{(i)}\}_{i=1}^m \sim \mathbb{P}_r$  a batch from the real data.
4:     Sample  $\{z^{(i)}\}_{i=1}^m \sim p(z)$  a batch of prior samples.
5:      $g_w \leftarrow \nabla_w \left[ \frac{1}{m} \sum_{i=1}^m f_w(x^{(i)}) - \frac{1}{m} \sum_{i=1}^m f_w(g_\theta(z^{(i)})) \right]$ 
6:      $w \leftarrow w + \alpha \cdot \text{RMSPProp}(w, g_w)$ 
7:      $w \leftarrow \text{clip}(w, -c, c)$ 
8:   end for
9:   Sample  $\{z^{(i)}\}_{i=1}^m \sim p(z)$  a batch of prior samples.
10:   $g_\theta \leftarrow -\nabla_\theta \frac{1}{m} \sum_{i=1}^m f_w(g_\theta(z^{(i)}))$ 
11:   $\theta \leftarrow \theta - \alpha \cdot \text{RMSPProp}(\theta, g_\theta)$ 
12: end while
```

---

Рисунок 28. Алгоритм обучения GAN.

Поскольку GAN содержит две отдельные сети, алгоритм обучения должен совмещать два разных вида обучения. Процессы обучения генератора и дискриминатора отличаются.

Обучение происходит следующим образом:

1. Дискриминатор обучается в течение одной или нескольких эпох.
2. Генератор обучается в течение одной или нескольких эпох.
3. Повторяем шаги 1 и 2, чтобы продолжить обучение сетей генератора и дискриминатора.

На этапе обучения дискриминатора генератор сохраняется постоянным. Поскольку цель дискриминатора научиться распознавать недостатки генератора на всех этапах его эволюции от случайного до обученного.

Точно так же дискриминатор сохраняется неизменным на этапе обучения генератора. В противном случае генератор может не сойтись, потому что будет стремиться решать постоянно изменяющуюся задачу.

По мере того, как генератор прогрессирует, производительность дискриминатора ухудшается, потому что дискриминатор больше не может отличать настоящее от подделки. Если генератор работает идеально, то точность дискриминатора составляет 50% [26].

Такое развитие создает проблему для сходимости GAN в целом: обратная связь дискриминатора со временем становится менее значимой. Если GAN продолжает обучение после точки, когда дискриминатор дает полностью случайную обратную связь, тогда генератор начинает обучаться на бесполезной обратной связи, и его собственный прогресс может ухудшиться. [26]

Алгоритм обучения представлен на рисунке 28.



## 4. ТЕСТИРОВАНИЕ И АНАЛИЗ

### 4.1 Условия эксперимента

Для обучения Wasserstein GAN, записи логов, построения графиков и валидации результатов был реализован бэкенд на языке программирования Python с использованием фреймворка для машинного обучения PyTorch. Процесс обучения осуществлялся на Cuda совместимом ускорителе.




Рисунок 29. Детальная структура генератора и дискриминатора.

Предлагаемый GAN построен на архитектуре DCGAN [24] и содержит симметрично структурированные генератор и дискриминатор. Подробная визуализация структуры представлена на рисунке 29.

Пакетная нормализация (Batch normalization - BN) [25] может значительно повысить скорость обучения и ускорить процесс сходимости. BN применяется ко всем слоям, кроме выходного слоя генератора и входного/выходного слоёв дискриминатора.

В генераторе для всех слоёв, кроме выходного используется функция активации ReLU [26].

Для всех слоёв дискриминатора используется функция активации Leaky ReLU [27] с коэффициентом отрицательного уклона 0,2.

## 4.2 Результаты

Анализ промежуточных результатов обучения нейронной сети показывает, что наблюдается стабильная сходимость в сети генератора и дискриминатора. График зависимости значений функции ошибки для генератора и дискриминатора от числа итераций алгоритма обучения представлен на рисунке 30.




Рисунок 30. График зависимости значений функции ошибки от числа итераций алгоритма обучения.

Количественные результаты интерполяции Кригингом, сплайном, методом обратно взвешенных расстояний (IDW) и предложенным методом на основе генеративно-состязательной нейронной сети с функцией потерь Вассерштейна представлены в таблице 2.

<b>Метод</b>	<b>ME</b>	<b>SD</b>	<b>MAE</b>	<b>RMSE</b>
WGAN	0.63	89.92	49.65	89.92
Kriging	0.15	82.32	46.22	82.34
Spline	0.91	62.43	35.45	62.43
IDW	-0.56	81.66	39.51	81.66

Таблица 3. Количественные результаты интерполяции различными методами.

## **ЗАКЛЮЧЕНИЕ**

В ходе выполнения работы было произведено подробное исследования предметной области, выполнен анализ существующих решений проблемы заполнения пустот в цифровых моделях рельефа. Выявлены преимущества и недостатки этих методов, границы их применимости и потенциал для использования тех или иных подходов для решения более узконаправленных задач в этой области. В результате произведенного обзора было выявлено, что детерминированные математические методы качественно решают задачу заполнения пустот в пересеченной местности, но обладают ограниченными возможностями в областях с плотной городской застройкой. Также были рассмотрены методы на основе глубокого машинного обучения, а именно, генеративные состязательные модели искусственного интеллекта, которые показывают положительные качественные и количественные результаты в решении задачи заполнения пустот даже в сложной местности с низким качеством исходных данных. В процессе исследования было выявлено, что задача по заполнению пустот в цифровых моделях рельефа остаётся решенной лишь частично, и области с плотной городской застройкой практически не рассматриваются, а исследования, которые затрагивают эту тему, не пришли к какому-либо значительному успеху. В результате проделанной работы был предложен алгоритм, основанный на модели генеративно-состязательной нейронной сети, для решения задачи преобразования цифровых моделей поверхности в цифровые модели рельефа посредством удаления зданий и прочих искусственных сооружений с последующим заполнением образовавшихся пустот.

Для решения задачи по обучению модели генеративно-состязательной нейронной сети необходимо было сформировать обучающий набор данных. Для этого был произведен поиск доступных источников цифровых моделей рельефа с мировым охватом, проведён качественный и количественный анализ

найденных датасетов, сформирована сравнительная таблица и сделаны выводы о возможном их применении для конечной агрегации. Также были рассмотрены источники данных о городской застройке и влиянии на рельеф местности. По итогу проделанной работы наборы ЦМР Alos 3D World и Copernicus были выбраны как наиболее точные. Для получения данных о вмешательстве человека в естественный рельеф было решено использовать Open Street Map и World Settlement Footprint.

В процессе подготовки обучающей коллекции цифровых моделей поверхности была произведена агрегация данных из выбранных источников. Информация о застройке была нанесена на исходные данные ЦМП в виде бинарной маски, что привело к образованию пустот, которые затем были заполнены при помощи выбранных в результате предварительного анализа детерминированных методов интерполяции. Полученный набор был разделён на обучающий и тестовый датасеты и в дальнейшем использован для обучения нейронной сети.

Также был произведён анализ инструментальных средств пространственного анализа, библиотек для обработки графических данных и решения задач машинного обучения. Выбраны наиболее подходящие для решения поставленных задач инструменты.

Предлагаемый алгоритм был реализован с использованием фреймворка машинного обучения PyTorch на языке программирования Python в ходе выполнения практической работы. В результате экспериментов с различными агрегациями входных данных и гиперпараметрами нейронных сетей была получена модель, которая с определённой точностью позволяет выполнять преобразование цифровых моделей поверхности в цифровые модели рельефа посредством удаления искусственных сооружений и изменений исходной поверхности.

В результате проведённых экспериментов были сделаны выводы об ограничениях полученного алгоритма, выявлены его сильные и слабые стороны. Качественные и количественные оценки алгоритмов на основе глубокого машинного обучения в значительной степени зависят от исходных данных, которые были использованы для их обучения. Повысить показатели предложенного алгоритма возможно, получив доступ к более точным наборам данных цифровых моделей рельефа, доступ к которым ограничен. Также возможно агрегировать большие объёмы разрозненных данных из других источников, например данные ЦМП крупных городов, полученных лидарным сканированием с дронов. Этот процесс достаточно сложно автоматизировать, так-как почти на всех этапах совмещения данных требуется экспертная оценка посредством визуального анализа.

При незначительной доработке интерфейса полученный на данном этапе работы метод можно применять в практике пространственного анализа и геомоделирования как отдельную библиотеку или реализовать в виде модуля для геоинформационной системы, например для QGIS.

Работа демонстрирует возможность применения генеративных алгоритмов на основе глубоких нейронных сетей для решения задачи удаления зданий из областей цифровых моделей поверхности с плотной городской застройкой.

Код практической части работы доступен в репозитории [Github](#).

## СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Saleem N. et al. Parameters derived from and/or used with digital elevation models (DEMs) for landslide susceptibility mapping and landslide risk assessment: a review //ISPRS International Journal of Geo-Information. – 2019. – Т. 8. – №. 12. – С. 545.
2. Xu K. et al. The Importance of Digital Elevation Model Selection in Flood Simulation and a Proposed Method to Reduce DEM Errors: A Case Study in Shanghai //International Journal of Disaster Risk Science. – 2021. – Т. 12. – №. 6. – С. 890-902.
3. Kakaletsis E., Nikolaidis N. Potential UAV landing sites detection through Digital Elevation Models analysis //arXiv preprint arXiv:2107.06921. – 2021.
4. Wu Q. et al. Efficient delineation of nested depression hierarchy in digital elevation models for hydrological analysis using level-set method //JAWRA Journal of the American Water Resources Association. – 2019. – Т. 55. – №. 2. – С. 354-368.
5. Fernández T. et al. Multitemporal analysis of gully erosion in olive groves by means of digital elevation models obtained with aerial photogrammetric and LiDAR data //ISPRS International Journal of Geo-Information. – 2020. – Т. 9. – №. 4. – С. 260.
6. Bove G. et al. A method for regional estimation of climate change exposure of coastal infrastructure: Case of USVI and the influence of digital elevation models on assessments //Science of The Total Environment. – 2020. – Т. 710. – С. 136162.
7. Gavriil K., Muntingh G., Barrowclough O. J. D. Void filling of digital elevation models with deep generative models //IEEE Geoscience and Remote Sensing Letters. – 2019. – Т. 16. – №. 10. – С. 1645-1649.

8. Pavlova A. I. Analysis of elevation interpolation methods for creating digital elevation models //Optoelectronics, Instrumentation and Data Processing. – 2017. – T. 53. – №. 2. – C. 171-177. [2] Filippini, Massimo, and Lester C. Hunt. (2012) “US residential energy demand and energy efficiency: A stochastic demand frontier approach.” *Energy Economics* **34** (5): 1484–1491.
9. Okolie C. J., Smit J. L. A systematic review and meta-analysis of Digital elevation model (DEM) fusion: pre-processing, methods and applications //ISPRS Journal of Photogrammetry and Remote Sensing. – 2022. – T. 188. – C. 1-29.
10. Rojas-Gonzalez S., Van Nieuwenhuyse I. A survey on kriging-based infill algorithms for multiobjective simulation optimization //Computers & Operations Research. – 2020. – T. 116. – C. 104869.
11. Skytt V., Dokken T. Scattered Data Approximation by LR B-Spline Surfaces: A Study on Refinement Strategies for Efficient Approximation //Geometric challenges in isogeometric analysis. – Springer, Cham, 2022. – C. 217-258.
12. YASTIKLI N., Jacobsen K. Automatic digital elevation model generation, problems and restrictions in urban areas //Journal of Yildiz Technical University. – 2003. – T. 2. – C. 38-46.
13. Erdogan S. A comparison of interpolation methods for producing digital elevation models at the field scale //Earth surface processes and landforms. – 2009. – T. 34. – №. 3. – C. 366-376.
14. Qiu Z., Yue L., Liu X. Void filling of digital elevation models with a terrain texture learning model based on generative adversarial networks //Remote Sensing. – 2019. – T. 11. – №. 23. – C. 2829.
15. Yue L. et al. High-quality seamless DEM generation blending SRTM-1, ASTER GDEM v2 and ICESat/GLAS observations //ISPRS Journal of Photogrammetry and Remote Sensing. – 2017. – T. 123. – C. 20-34.



16. Han Y. et al. State of the art in digital surface modelling from multi-view high-resolution satellite images //ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences. – 2020. – T. 2. – C. 351-356.
17. Li S. et al. Integrating topographic knowledge into deep learning for the void-filling of digital elevation models //Remote Sensing of Environment. – 2022. – T. 269. – C. 112818.
18. Arun P. V. A comparative analysis of different DEM interpolation methods //The Egyptian Journal of Remote Sensing and Space Science. – 2013. – T. 16. – №. 2. – C. 133-139.
19. Karras T. et al. Progressive growing of gans for improved quality, stability, and variation //arXiv preprint arXiv:1710.10196. – 2017.
20. Arjovsky M., Chintala S., Bottou L. Wasserstein generative adversarial networks //International conference on machine learning. – PMLR, 2017. – C. 214-223.
21. Radford A., Metz L., Chintala S. Unsupervised representation learning with deep convolutional generative adversarial networks //arXiv preprint arXiv:1511.06434. – 2015.
22. Ioffe S., Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift //International conference on machine learning. – pmlr, 2015. – C. 448-456.
23. Nair V., Hinton G. E. Rectified linear units improve restricted boltzmann machines //Proceedings of the 27th international conference on machine learning (ICML-10). – 2010. – C. 807-814.
24. He K. et al. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification //Proceedings of the IEEE international conference on computer vision. – 2015. – C. 1026-1034.

25. Gulrajani I. et al. Improved training of wasserstein gans //Advances in neural information processing systems. – 2017. – Т. 30.
26. Намиот Д.Е., Ильюшин Е.А. Порождающие модели в машинном обучении. International Journal of Open Information Technologies. 2022. Т. 10. № 7. С. 101-118